

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación

Laboratorio 4. Parte 2

Modelos con datos geoespaciales

Avance: ejercicios 1 al 3

Curso: CC3084 – Data Science
Integrantes: Milton Polanco
Osman de León
Fecha: 20 de agosto de 2026

1. Introducción

En este avance se transformaron las imágenes de la primera parte en un conjunto de datos por píxel. Cada fila conserva la ubicación, fecha, lago, reflectancias e índices necesarios para el análisis. Luego se construyó una respuesta binaria para distinguir una presencia baja o ausente de una presencia alta de cianobacteria, y se definió el conjunto inicial de predictores.

El indicador utilizado es una estimación satelital de clorofila-a basada en NDCI. Por esta razón, la clase representa una señal para priorizar zonas de monitoreo y no una confirmación de toxicidad. Para confirmar una floración se necesitarían conteos celulares, identificación de especies y mediciones de toxinas en campo.

2. Preparación de los datos para Machine Learning

2.1. Unidad de observación y sistema de coordenadas

La unidad de análisis es un píxel válido de 20 m dentro de uno de los lagos. Todas las bandas se llevaron a una malla común en WGS 84 / UTM zona 15N (EPSG:32615). Este sistema conserva las coordenadas en metros y también servirá para construir los bloques de validación espacial en el siguiente avance. Se guardaron adicionalmente longitud y latitud para facilitar la visualización.

Se procesaron 21 de las 22 combinaciones de lago y fecha. El catálogo no devolvió una adquisición Sentinel-2C sobre Atitlán para el 13 de abril de 2025. La fecha se mantuvo en el resumen de auditoría con cero observaciones y no se substituyó por otro día.

Cuadro 1: Cantidad de observaciones después de la limpieza.

Lago	Fechas con datos	Observaciones	Parte del total (%)
Amatitlán	11	247,417	13.89
Atitlán	10	1,533,769	86.11
Total	21	1,781,186	100.00

Cuadro 2: Cantidad de observaciones por lago y fecha.

Amatitlán		Atitlán	
Fecha	Obs.	Fecha	Obs.
2025-01-28	26,707	2025-01-18	133,406
2025-04-15	9,970	2025-04-13	0
2025-04-28	22,053	2025-05-13	158,034
2025-11-24	29,435	2025-07-17	15,453
2026-01-08	30,771	2025-11-21	181,153
2026-02-02	2,441	2025-12-29	187,040
2026-02-07	7,746	2026-02-12	203,767
2026-03-29	21,532	2026-03-24	287,845
2026-04-13	33,893	2026-04-13	39,680
2026-04-28	32,697	2026-04-28	120,087
2026-06-19	30,172	2026-07-22	207,304

La diferencia entre lagos se explica principalmente por su superficie. Atitlán aporta más filas porque cubre una extensión considerablemente mayor. Esta diferencia debe considerarse durante el entrenamiento para evitar que el comportamiento de Atitlán domine el ajuste global.

2.2. Limpieza y control de calidad

La preparación se realizó con las siguientes reglas:

1. Las reflectancias de Sentinel-2 L2A se dividieron entre 10,000 y se remuestrearon a 20 m.
2. Se retiraron las clases SCL 0, 3, 8, 9, 10 y 11, que corresponden a píxeles sin datos, sombra de nube, nubes, cirrus y nieve o hielo.
3. El agua se identificó combinando NDWI, MNDWI y AWEI. Se eliminaron componentes conectados menores de 0.1 km². El límite retira manchas aisladas dentro del rectángulo de consulta, pero mantiene los dos sectores de Amatitlán separados por el relleno construido sobre el lago.
4. Se exigieron valores positivos en las siete bandas y una estimación finita de clorofila-a entre 0 y 500 mg/m³.
5. Las observaciones que no cumplieron los criterios se eliminaron. No se imputaron bandas, índices ni etiquetas.

Después de aplicar estas reglas, las 1,781,186 filas tienen información completa: el porcentaje de valores faltantes es 0 % en las 25 variables. Tampoco se encontraron filas duplicadas exactas.

Cuadro 3: Variables, tipos almacenados y porcentaje de valores faltantes.

Grupo	Variables	Tipo	Faltantes (%)
Identificación	lago y satélite	str	0.00
Identificación	fecha	datetime64[us]	0.00
Identificación	fila y columna	int32	0.00
Coordenadas	x UTM, y UTM, longitud y latitud	float32	0.00
Temporales	año	int16	0.00
Temporales	mes	int8	0.00
Temporales	seno y coseno del día del año	float32	0.00
Bandas	B02, B03, B04, B05, B08, B11 y B12	float32	0.00
Índices	NDVI, NDWI y NDCI	float32	0.00
Respuesta	clorofila-a estimada	float32	0.00
Respuesta	clase binaria	int8	0.00

2.3. Análisis exploratorio

La mediana global del indicador fue 4.07 mg/m³, mientras que el percentil 95 fue 21.41 mg/m³. La distribución tiene una cola derecha larga y alcanza valores puntuales superiores a 400 mg/m³. Para que la parte central pueda distinguirse, en la Figura 1 los valores superiores al percentil 99 se muestran en el último intervalo.




Figura 1: Distribución de clorofila-a estimada por lago. La línea punteada marca el punto de corte usado para la respuesta.

Atitlán se concentra cerca de 4 mg/m³. Amatitlán muestra una distribución más amplia y una

proporción importante por encima del umbral. La visualización espacial también confirma que las observaciones siguen la forma general de ambos lagos y que la clase alta no se presenta de forma uniforme.




Figura 2: Distribución espacial de la clase en una muestra de 120,000 píxeles. En rojo se muestran las observaciones de clase alta.

3. Construcción de la variable respuesta

3.1. Definición y punto de corte

La concentración estimada se obtuvo a partir de B04 y B05:

$$NDCI = \frac{B05 - B04}{B05 + B04}, \quad (1)$$

$$Chl-a = 826.57(NDCI)^3 - 176.43(NDCI)^2 + 19(NDCI) + 4.071. \quad (2)$$

El polinomio se reprodujo del evalscript de CyanoLakes utilizado en la primera parte del laboratorio.

Se definió la variable respuesta como:

$$y = \begin{cases} 1, & Chl-a \geq 12 \text{ mg/m}^3, \\ 0, & Chl-a < 12 \text{ mg/m}^3. \end{cases} \quad (3)$$

Un mg/m^3 equivale numéricamente a un $\mu\text{g/L}$. Las guías de la Organización Mundial de la Salud para aguas recreativas ubican entre 12 y 24 $\mu\text{g/L}$ de clorofila-a el nivel de alerta 1 cuando predominan cianobacterias. Se utilizó el límite inferior porque separa el nivel de vigilancia de una condición que ya requiere una revisión más cercana.

El criterio depende de que la señal de clorofila-a sea dominada por cianobacterias. Como no se cuenta con mediciones simultáneas de laboratorio, la clase debe interpretarse como una etiqueta operativa construida para el ejercicio, no como una clasificación sanitaria definitiva.

3.2. Distribución y desbalance

Cuadro 4: Distribución de la variable respuesta.

Grupo	Clase baja	Clase alta	Alta (%)
Amatitlán	113,905	133,512	53.96
Atitlán	1,512,531	21,238	1.38
Total	1,626,436	154,750	8.69




Figura 3: Porcentaje de observaciones de clase baja y alta en cada lago.

Globalmente hay cerca de 10.5 observaciones bajas por cada observación alta. El contraste por lago es aún más importante: la clase alta es mayoritaria en Amatitlán, pero representa solo 1.38 % en Atitlán. Un modelo que casi siempre prediga la clase 0 podría obtener una exactitud global alta y aun así omitir las zonas de mayor interés ambiental.

En los ejercicios de modelado se mantendrá la distribución real en el conjunto de prueba. Dentro del entrenamiento se evaluará ponderación de clases y se usará una partición estratificada. Además de ROC-AUC, se dará atención al recall y al F1 de la clase alta, porque no detectar una zona realmente alta puede retrasar el muestreo o una respuesta preventiva.




Figura 4: Proporción de píxeles de clase alta por lago y fecha.

Amatitlán presenta variaciones grandes entre fechas y llega a 98.46 % de píxeles altos el 19 de junio de 2026. Atitlán alcanza 12.46 % el 18 de enero de 2025 y se mantiene por debajo de 1.53 % en las demás observaciones. Esta dependencia entre fecha, lago y clase significa que una división aleatoria de píxeles puede mezclar observaciones casi idénticas entre entrenamiento y prueba; la validación espacial y temporal será necesaria para medir generalización real.

3.3. Variables excluidas por fuga de información

Cuadro 5: Variables que no se utilizarán como predictoras.

Variable	Razón de exclusión
B04	Se usa directamente para calcular NDCI.
B05	Se usa directamente para calcular NDCI.
NDCI	Es la entrada directa del polinomio que produce la clorofila-a estimada.
Clorofila-a estimada	La clase se obtiene aplicando el umbral a esta misma variable.
NDVI	Incluye B04, por lo que comparte una entrada con la construcción de la respuesta.

Estas columnas se conservan en el archivo para auditar y reproducir la etiqueta, pero no entrarán a los modelos ni se crearán transformaciones que las reintroduzcan.

4. Selección y construcción de variables predictoras

El conjunto inicial conserva información espectral, espacial y temporal que no interviene directamente en la etiqueta.

Cuadro 6: Predictores propuestos para los modelos.

Variable	Tipo	Justificación
B02	Banda espectral	Reflectancia azul; responde a dispersión y cambios de color del agua.
B03	Banda espectral	Reflectancia verde; puede cambiar con pigmentos y claridad del agua.
B08	Banda espectral	Infrarrojo cercano; ayuda a diferenciar agua, material flotante y bordes.
B11 y B12	Bandas espectrales	Las bandas SWIR aportan contraste ante humedad, turbidez y contaminación residual.
NDWI	Índice	Resume el contraste entre verde e infrarrojo cercano sin utilizar B04 ni B05.
x UTM, y UTM	Espaciales	Conservan gradientes y sectores del lago en una unidad métrica.
Lago	Categoría	Representa diferencias de tamaño, cuenca y comportamiento espectral.
Año	Temporal	Permite separar las dos temporadas anuales observadas.

Variable	Tipo	Justificación
Seno y coseno del día	Temporal cíclica	Representan estacionalidad sin introducir un salto artificial entre diciembre y enero.

La variable lago se codificará con one-hot encoding. Para la regresión logística, las variables continuas se estandarizarán dentro del pipeline; Random Forest y Gradient Boosting recibirán las escalas originales. Longitud y latitud se excluyen porque duplican x UTM e y UTM. Mes se excluye porque la estacionalidad ya está representada mediante seno y coseno. Satélite, fila y columna se mantienen solamente como metadatos.




Figura 5: Matriz de correlación de los predictores numéricos propuestos, calculada sobre una muestra reproducible de 120,000 observaciones.

Las bandas tienen correlaciones fuertes. B11 y B12 alcanzan aproximadamente 0.98. Esto puede volver inestables los coeficientes de una regresión logística sin regularización, aunque no afecta de la misma manera a los modelos de árboles. Durante el ajuste se comparará el desempeño conservando ambas bandas y retirando una de ellas. También se revisará la utilidad de las coordenadas

mediante validación espacial, porque una partición aleatoria puede sobreestimar su aporte debido a la autocorrelación entre píxeles vecinos.

5. Conclusiones del avance

- Se construyó un conjunto de 1,781,186 píxeles válidos con coordenadas, fecha, lago, bandas e índices. No quedaron valores faltantes después de la limpieza.
- Se usó 12 mg/m^3 como punto de corte por corresponder al inicio del nivel de alerta 1 de la OMS cuando predominan cianobacterias.
- La clase alta representa 8.69 % globalmente, pero 53.96 % en Amatitlán y 1.38 % en Atitlán. Esta diferencia exige evaluar métricas sensibles a la clase alta y separar cuidadosamente los datos.
- B04, B05, NDCI, clorofila-a estimada y NDVI fueron excluidos de los predictores para evitar fuga de información.
- El conjunto predictor combina bandas no utilizadas por la etiqueta, NDWI, ubicación y variables temporales cíclicas. Su aporte se comprobará posteriormente con validación aleatoria, espacial y entre lagos.

Referencias

1. World Health Organization. (2021). *Guidelines on recreational water quality. Volume 1: Coastal and fresh waters*. Disponible en: <https://www.who.int/publications/i/item/9789240031302>
2. Mishra, S. y Mishra, D. R. (2012). Normalized Difference Chlorophyll Index: A novel model for remote estimation of chlorophyll-a concentration in turbid productive waters. *Remote Sensing of Environment*, 117, 394–406. <https://doi.org/10.1016/j.rse.2011.10.016>
3. Kravitz, J. y Matthews, M. (2020). *Cyanobacteria Chlorophyll-a NDCI L1C*. Sentinel Hub Custom Scripts. https://custom-scripts.sentinel-hub.com/custom-scripts/sentinel-2/cyanobacteria_chla_ndci_l1c/
4. Copernicus Data Space Ecosystem. *Sentinel-2 Level-2A*. <https://documentation.dataspace.copernicus.eu/Data/SentinelMissions/Sentinel2.html>